



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Clase N° 1

Introducción a las analíticas de recursos humanos y la inteligencia artificial

Uso de la inteligencia artificial en la gestión de recursos humanos

Docente

Raicho Bojilov

Contenido

Introducción	4
1. Introducción a las analíticas de recursos humanos e la inteligencia artificial.....	6
1.1 Analíticas de recursos humanos.....	6
1.2 La inteligencia artificial y su aplicación a las analíticas de recursos humanos...	10
1.2.1 Definiciones	10
2.2.2 Aplicación de la inteligencia artificial a las analíticas de recursos humanos	10
2. Aprendizaje autónomo y métodos estadísticos clásicos.....	12
2.1 El problema	12
2.2 Estimación de F	12
2.2.1 Regresión lineal.....	13
2.2.2 Regresión no lineal	15
2.2.3 Algoritmos de aprendizaje autónomo	17
2.2.4 Algoritmo "Random forest"	17
2.2.5 GPT, ChatGPT, etc.	18
2.3 Gestión de la aplicación de IA a las analíticas de RRHH.....	19
Conclusión	20
Preguntas:	21
Bibliografía.....	22

Resultados de aprendizaje

- Revisar las tendencias recientes en análisis de personas.
- Relacionar los métodos estadísticos avanzados, específicamente la IA, con los métodos estadísticos clásicos.
- Deducir algunas buenas prácticas para la gestión de la aplicación de la IA al análisis de recursos humanos.

Introducción

Las analíticas de recursos humanos han sido pioneras en la adopción temprana de métodos estadísticos avanzados, especialmente en el uso de la inteligencia artificial (IA). De acuerdo con una encuesta global realizada por Davenport y Anderson (Oracle White Paper, 2019) y analizada por Davenport (HBR, 2019), los departamentos de recursos humanos (RRHH) son algunas de las unidades que más han adoptado métodos estadísticos avanzados a nivel mundial, superando incluso en ciertos aspectos a áreas tradicionalmente enfocadas en el análisis cuantitativo, como finanzas. Por ejemplo, el 51 % de los encuestados de RRHH afirmaron que podían realizar análisis predictivos, mientras que solo el 37 % de los encuestados de finanzas podían hacer lo mismo. Además, el 31 % de los encuestados de RRHH indicaron que sus unidades utilizan IA, donde las áreas más comunes de aplicación son: “identificación de talento en riesgo de rotación,” “predicción de candidatos de alto desempeño” y “búsqueda de candidatos con el mejor perfil a través del análisis de currículos”. Estas tendencias se han acelerado durante la pandemia de COVID y el período posterior.

Además, la relevancia de las analíticas de recursos humanos en la gestión general de las empresas y en el diseño de estrategias empresariales ha aumentado considerablemente. Según Ferrar, Verghese y Chakrabati (2024), el porcentaje de unidades de analítica de personas en EE. UU. que comparten datos e ideas con los gerentes de toda la empresa creció al 63 % en 2023 y al 71 % en 2024.

Al mismo tiempo, el informe de la OCDE “El Futuro del Trabajo” indica que los ejecutivos de RRHH se encuentran entre los profesionales que enfrentan el menor o inexistente riesgo de reemplazo por la automatización. (Consulte la Figura 1, donde el eje horizontal representa el riesgo de automatización, el eje vertical el salario anual, el tamaño de cada círculo el porcentaje de la mano de obra en cada profesión y su color representa la educación requerida para la profesión). Este resultado plantea la pregunta: ¿por qué las personas en una de las unidades más orientadas hacia la adopción de la inteligencia artificial son también algunas de las menos propensas a ser reemplazadas por la automatización, específicamente por la IA?

Durante esta clase, analizaremos las razones por las cuales los métodos estadísticos avanzados, en particular la inteligencia artificial, no sustituyen, sino que complementan el talento de los gerentes de recursos humanos. Para hacer eso, comenzaremos con una revisión general del tema de las analíticas de RRHH: las tendencias recientes, los posibles retornos de inversión, las etapas de implementación de las analíticas de personas y las mejores prácticas. A continuación, ofreceremos una

definición formal de la IA, presentaremos los métodos estadísticos y los algoritmos utilizados en su desarrollo, y exploraremos algunas lecciones sobre la gestión de la adopción de la IA en el ámbito de los recursos humanos.




Figura 1: Riesgo de automatización por profesión en los EE.UU. Fuente: OECD.

1. Introducción a las analíticas de recursos humanos e la inteligencia artificial

1.1 Analíticas de recursos humanos

El uso de las analíticas de RRHH ha seguido ampliándose en los últimos años. Esta tendencia se ha acelerado con la introducción de productos basados en, o similares a, ChatGPT. Sin embargo, persiste un desafío importante: aunque más del 71 % de las empresas en EE. UU. utilizan de alguna forma datos e ideas provenientes de las analíticas de RRHH, el diseño y la adopción de herramientas para tomar decisiones basadas en estos datos e ideas siguen rezagados (ver Figura 2).

El equilibrio entre la precisión de las predicciones y la escala y alcance de la aplicación sigue siendo un obstáculo importante para el desarrollo y uso generalizado de herramientas efectivas de toma de decisiones basadas en las analíticas de RRHH. Por esta razón, medir y demostrar el valor agregado de las analíticas y las herramientas de RRHH es esencial para que los equipos de analíticas de RRHH aumenten su impacto.

A pesar de lo intuitiva que puede parecer esta recomendación, sorprendentemente, solo alrededor de un tercio de los equipos de analíticas de RRHH mantienen y reportan de manera consistente métricas de desempeño de sus productos analíticos (ver Figura 3). Ferrar, Verghese y Chakrabati (2024) ofrecen una revisión más detallada de las tendencias recientes en la industria.

% de respuestas favorables a las afirmaciones




Figura 2: Diferencias entre el uso de analíticas de RR.HH. y la creación y adopción de herramientas asociadas de toma de decisiones. Fuente: Ferrar, Verghese, Chakrabati (2024).

En mi empresa, el líder de People Analytics cree que evidenciar el valor del trabajo de People Analytics es importante para que la función tenga impacto.

93%

Medimos de manera consistente el impacto de los proyectos de People Analytics que entregamos.

37%

Figura 3: La diferencia entre la necesidad expresada y la implementación real de medidas del desempeño de las herramientas analíticas de RRHH. Fuente: Ferrar, Verghese, Chakrabati (2024).

Como cualquier proyecto, los relacionados con herramientas de IA pasan por un proceso de evolución con distintas etapas. Como siempre, hay una etapa inicial de exploración y desarrollo. Después, vienen las etapas de implementación y retroalimentación y un proyecto exitoso termina con la integración de los resultados entre las competencias claves de la empresa. □ Lesser, DeBellis y Solow (2023) de Deloitte, identifican cuatro etapas distintas en el desarrollo de cada proyecto de analíticas de RRHH.

Etapas 1: Exploración y desarrollo

Esta etapa involucra la recopilación de datos, su limpieza y la sistematización del registro de datos para el futuro. Con frecuencia, este trabajo preparatorio es subestimado y poco valorado. Sin embargo, es crucial para el éxito de un proyecto. La cultura de datos es el mayor predictor del desempeño de la analítica de RRHH.

La exploración incluye la revisión de estadísticas descriptivas y regresiones simples, que requieren muy pocos supuestos técnicos. El objetivo aquí es transformar la pregunta gerencial en hipótesis estadísticas simples que puedan ser probadas usando datos y herramientas básicas. De este modo, se permite que los datos "hablen" tanto como sea posible. Al final de la exploración, se debe determinar si los datos muestran relaciones fuertes que necesitan estimarse con mayor precisión mediante herramientas más avanzadas. Si los datos no muestran nada sólido o interesante, las herramientas avanzadas no pueden generar resultados de calidad y origen claro.

Si el análisis exploratorio es satisfactorio, se pueden aplicar herramientas más avanzadas para mejorar la precisión de las predicciones. Es importante encontrar formas de presentar los resultados del producto final de manera intuitiva que refuercen o añadan matices a la "historia" del análisis exploratorio.

Etapas 2: Escala e implementación

Muy a menudo, las empresas aplican la etapa 1 como un proyecto piloto. En caso de éxito, surge el desafío de escalar la herramienta analítica a todas las unidades de la empresa o a distintas empresas/clientes. La actualización de la herramienta y su evaluación en el nuevo contexto más general también requieren el diseño de un sistema para actualizar las bases de datos utilizadas por el producto. Estos desafíos destacan la importancia de las buenas prácticas de datos. El uso de identificadores uniformes, nomenclaturas comunes, las mismas aplicaciones de *software*, la automatización de la agregación de datos y el mantenimiento de notas detalladas sobre la generación de datos son cruciales para la resolución exitosa de estos desafíos.

Al final de esta etapa, los equipos de analítica deben contar con una herramienta intuitiva y fácil de usar por el usuario promedio potencial. El diseño de estas herramientas sigue siendo un gran desafío. De hecho, una de las razones del éxito de

GPT es la implementación de ChatGPT, que permite una interacción intuitiva entre los usuarios y los algoritmos.

Etapa 3: Colaboración y retroalimentación

Como exploraremos durante el curso, los temas estudiados utilizando datos de RRHH casi siempre están relacionados con cuestiones más amplias y complejas que involucran más de una unidad y, a menudo, están vinculadas a la estrategia empresarial. Por lo tanto, es importante que los equipos de analítica de RRHH involucren a los profesionales y analistas de las unidades relacionadas en todas las etapas. Esta práctica es particularmente importante en la etapa de recepción de comentarios y la discusión sobre futuras iteraciones del producto.

Etapa 4: Institucionalización y transformación

El objetivo final de todo el proceso debe ser el diseño de una herramienta que se convierta en parte de la estrategia empresarial y en una característica distintiva que ofrezca una ventaja corporativa a toda la empresa en comparación con sus competidores.

Como muestra la Figura 4, se observan avances en la evolución de productos de una etapa a la siguiente. Sin embargo, muy pocos productos basados en analíticas de RRHH alcanzan la etapa 4. A pesar de eso, como revelan Waters, Eatough, Bashir y O'Keefe (2024), la adopción de las analíticas de RRHH está asociada con un mayor retorno de inversión, con un promedio de 6.2%.




Figura 4: Etapas en el desarrollo de proyectos analíticos de RRHH. Fuente: Deloitte.

1.2 La inteligencia artificial y su aplicación a las analíticas de recursos humanos

1.2.1 Definiciones

Comencemos la discusión sobre la aplicación de la inteligencia artificial en la analítica de recursos humanos con algunas definiciones formales.

Definición de inteligencia artificial: cualquier computador/mecanismo que recibe información de su entorno y toma decisiones que maximicen sus posibilidades de lograr algunos objetivos predeterminados.

La inteligencia artificial usa algoritmos de aprendizaje autónomo como "*random forest*", "aprendizaje reforzado" o algoritmos de redes neuronales.

Definición de aprendizaje autónomo (Samuel, 1959): aprendizaje autónomo es un área de estudio en la informática que utiliza técnicas estadísticas para dar a los computadores la capacidad de "aprender" con datos, sin una intervención explícita de los humanos.

El aprendizaje autónomo funciona con un algoritmo que aprende por sí solo utilizando datos históricos. La intervención humana se limita solo a: la definición de la función de utilidad (objetivos), el algoritmo y (la estructura de) los datos.

2.2.2 Aplicación de la inteligencia artificial a las analíticas de recursos humanos

Las aplicaciones de la IA en las analíticas de RRHH incluyen programación, resumen de información y la automatización de diversas tareas, como la creación de bases de datos a partir de documentos, videos, etc. ChatGPT y programas similares son excelentes para la preparación de programas preliminares ("borradores") que los usuarios "solo" necesitan "*debug*" o ajustar a los datos o contextos específicos. La definición del problema en el *prompt* de ChatGPT se ha transformado en un arte que puede ahorrar mucho tiempo en el proceso de automatización de algunos elementos de programación. En este contexto, las habilidades de programación siguen siendo importantes. Sin embargo, la contribución relativa del pensamiento crítico y las habilidades de resolución de problemas ha aumentado.

El avance de estas herramientas tiene el potencial de democratizar la adopción de las analíticas de RRHH por parte de pequeñas y medianas empresas, ya que permite análisis especializados y específicos de cada empresa.

Además, ChatGPT y programas similares son excelentes para resumir información. Por lo tanto, las aplicaciones inmediatas posibles incluyen el resumen de informes generados por diferentes unidades o por la misma unidad a lo largo del tiempo. También pueden usarse para analizar respuestas abiertas en encuestas o para resumir

los temas principales en las preguntas o comentarios de los participantes en reuniones.

Ejemplo

Sonnenberg, Bechini, Schröder y van Mil (2024) presentan el proceso de aplicación de GPT en combinación con algunos programas exclusivos de su organización para capturar las responsabilidades principales y habilidades de cada puesto en su empresa. Su estudio combina el uso de la IA como herramienta de resumen y programación. Los autores aún están trabajando en la creación de productos analíticos para el usuario promedio en la empresa.

Basándose en su experiencia con ChatGPT, ofrecen las siguientes sugerencias:

- **Seguridad de datos:** al trabajar con información confidencial de la empresa, utiliza la función Azure de OpenAI con GPT para garantizar el uso seguro de los datos.
- **Interacción:** *prompts*, preguntas o comentarios más cortos generan resultados más precisos. Si necesitas un texto más largo, asegúrate de que la información crucial esté al final, ya que el motor muestra sesgo de recencia.
- **Representación numérica:** GPT maneja mejor los números escritos en palabras que los dígitos numéricos (por ejemplo, "uno" en lugar de "1").
- **Redefinición:** el rendimiento de GPT varía según la formulación de la pregunta o comentario por parte del usuario. Por lo tanto, a veces desviarse de las "reglas" puede funcionar mejor. Prueba qué funciona mejor en cada caso.
- **Evaluación de versiones:** Las diferentes versiones de GPT tienen distintos rendimientos.

Consejos para la adopción:

- Invertir en la limpieza y gestión de datos.
- Pilotear aplicaciones de IA.
- Colaborar entre los equipos de RRHH, TI y ciencia de datos.
- Priorizar el aprendizaje de las mejores prácticas de gestión de datos y el uso ético de la IA en los programas de formación.

2. Aprendizaje autónomo y métodos estadísticos clásicos

Exploraremos la relación entre los métodos estadísticos clásicos y los algoritmos utilizados en el desarrollo de IA en el contexto de un problema clásico que enfrentan los equipos analíticos de RRHH.

2.1 El problema

La siguiente ecuación representa la relación entre la variable de interés y las características de los trabajadores o candidatos:

$$Y = F(X) + e$$

donde F es una función que vincula las características observadas al punto de postulación con los resultados después de la contratación. La relación causal hipotetizada determina qué variables son dependientes y cuáles son explicativas.

Por ejemplo, la ecuación podría ser:

$$\text{Productividad} = \text{const} + a_1.\text{exp} + a_2.\text{edu} + a_3.\text{uni} + a_4.\text{ref} + e$$

Donde:

- exp=experiencia
- edu=años de educación
- uni=universidad
- ref=tiene referencia (=1) o no (=0)
- e=error o factores exógenos

2.2 Estimación de F

Los computadores modernos permiten la estimación de F usando varios métodos de estimación de econometría, algoritmos, etc. El objetivo es recuperar F en una manera que ofrezca la mejor aproximación de la relación entre las características X y la variable de interés Y .

Consideramos en dificultad progresiva tres casos:

- Regresión lineal.
- Regresión no lineal.
- Algoritmos de aprendizaje autónomo.




Figura 5: Regresión lineal.

2.2.1 Regresión lineal

Las regresiones lineales estiman una relación lineal entre la variable dependiente Y y las variables explicativas $x_1, \dots, x_n$. La estimación lineal de la relación se determina minimizando la distancia cuadrática media entre las observaciones y la línea que contiene las predicciones del modelo. La línea resultante es la predicción del modelo y se caracteriza por una constante y una pendiente. La pendiente está determinada por los coeficientes de las variables explicativas incluidas en la regresión.

La relación entre la variable dependiente Y y cada una de las variables explicativas x_i está representada por **el coeficiente de x_i** . Este coeficiente se caracteriza por la magnitud y el signo del coeficiente estimado, por un lado, y por la precisión de la estimación del coeficiente, por otro. Intuitivamente, una magnitud grande indica que x_i es un factor importante en la determinación de la variable dependiente Y . Sin embargo, siempre debemos considerar también la precisión de las estimaciones, que está capturada por el error estándar. Un error grande indica que hay incertidumbre sobre el valor exacto del coeficiente.

Más técnicamente, **el error estándar** determina el tamaño del intervalo de confianza donde, con un 95 % de certeza, se encuentra el coeficiente. En el centro de este intervalo se encuentra el coeficiente estimado. Un error pequeño implica un intervalo más estrecho y, por lo tanto, mayor certeza sobre el valor del coeficiente.

Definimos **el estadístico t** como el cociente entre el coeficiente estimado y el error estándar:

$$t - stat = \frac{Coef}{Std.Err}$$

Se utiliza para probar la hipótesis de si el coeficiente es estadísticamente diferente de 0. Generalmente, la significancia se evalúa al nivel de confianza del 95 %; es decir, se prueba si el coeficiente es diferente de cero con un 95 % de confianza. En otras palabras, se evalúa si el 0 se encuentra dentro del intervalo de confianza del 95% del coeficiente.

Para determinar el resultado de la prueba:

$$H_0: coef=0$$

$$H_a: coef \neq 0$$

Comparamos el valor del estadístico t calculado anteriormente con el valor crítico para el nivel de confianza del 95 % de la distribución del estadístico t. Si el valor del estadístico t es lo suficientemente grande, rechazamos H_0 . Las aplicaciones estadísticas estándar realizan y reportan automáticamente los resultados de esta prueba.

Para probar la hipótesis más general:

$$H_0: coef=\alpha$$

$$H_a: coef \neq \alpha$$

Se calcula el siguiente estadístico:

$$t - stat = \frac{Coef - \alpha}{Std.Err}$$

Si la distancia cuadrática media entre la línea y las observaciones es grande, entonces la calidad de la predicción es baja. En otras palabras, la predicción explica una pequeña parte de la varianza en los datos observados. El R^2 es una estadística que es igual al porcentaje de la varianza en los datos que el modelo lineal predice. Al agregar variables adicionales, el R^2 aumenta automáticamente, independientemente de si las nuevas variables añadidas tienen un efecto estadísticamente significativo sobre la variable dependiente. Una posible solución a este problema es el R^2 ajustado, que introduce una penalización por la inclusión de nuevas variables. El R^2 ajustado solo aumenta si las variables añadidas tienen un efecto significativo en el resultado.

Una forma más general de evaluar la calidad del modelo lineal es mediante **pruebas fuera de muestra (out-of-sample testing)**. Como primer paso, dividimos de manera aleatoria la muestra en una muestra de entrenamiento (generalmente el 60%) y una muestra de prueba (generalmente el 40%). Los datos de entrenamiento se utilizan para estimar el modelo, y los datos de prueba se utilizan para evaluar la calidad de la aproximación. La lógica es intuitiva: podemos pensar en los datos de

prueba como datos del futuro que se generan mediante el mismo proceso que los datos de entrenamiento, pero que no están disponibles en el momento de la estimación del modelo.

Si nuestro modelo estimado es bueno para recuperar el proceso generador de datos, entonces el R^2 será alto tanto para los datos de entrenamiento como para los datos de prueba. Si hemos sobre ajustado el modelo (notemos que, en el extremo, al incluir tantas variables como observaciones, obtenemos una aproximación perfecta, $R^2=1$), entonces el R^2 para los datos de entrenamiento será alto, pero el R^2 para los datos de prueba será bajo.

En las regresiones lineales, el analista determina qué variables explicativas se incluyen. La forma funcional de la relación entre la variable dependiente y las variables explicativas, se fija para ser lineal o para ser reducible a lineal de una de las siguientes tres maneras:

Tipo 1: especificación lineal:

$$\text{Productividad} = \text{const} + a_1.\text{exp} + a_2.\text{edu} + a_3.\text{uni} + a_4.\text{ref} + e$$

Tipo 2: especificación log-lineal:

$$\text{Productividad} = e^{\text{const} + a_1.\text{exp} + a_2.\text{edu} + a_3.\text{uni} + a_4.\text{ref}} + e$$

Que se convierte en una relación lineal después de la transformación logarítmica:

$$\ln(\text{Productividad}) = \text{const} + a_1.\text{exp} + a_2.\text{edu} + a_3.\text{uni} + a_4.\text{ref} + e$$

Tipo 3: especificación log-log lineal:

$$\text{Productividad} = \text{const} \cdot \text{exp}^{a_1} \cdot \text{edu}^{a_2} \cdot \text{uni}^{a_3} \cdot \text{ref}^{a_4} \cdot e$$

Que se convierte en una relación lineal después de la transformación logarítmica:

$$\ln(\text{Productividad}) = \ln(\text{const}) + a_1.\text{exp} + a_2.\text{edu} + a_3.\text{uni} + a_4.\text{ref} + \ln(e)$$

La interpretación de los coeficientes es:

- **Especificación lineal:** un aumento de una unidad de x_i resulta en a_i unidades de cambio en la variable dependiente.
- **Especificación log-lineal:** un aumento de una unidad de x_i resulta en un cambio de $e^{a_i} - 1$ porcentajes en la variable dependiente (cuando a_i esté relativamente pequeño, el cambio en la variable dependiente es aproximadamente igual a a_i porcentajes).
- **Especificación log-log lineal:** un aumento de x_i porcentajes resulta en un cambio de a_i porcentajes de en la variable dependiente.

2.2.2 Regresión no lineal

Las regresiones no lineales relajan la suposición de que la relación entre la variable dependiente y las variables explicativas debe ser de uno de los tres tipos lineales (1-

3) presentados anteriormente. Esto significa que se pueden considerar todas las funciones posibles: polinomios, dividir cada variable continua en intervalos y estimar un modelo que incluya cada intervalo con su propio coeficiente, etc. Es decir, la regresión no lineal permite una mayor flexibilidad y resulta en una mejor aproximación de la relación entre la variable dependiente y las variables explicativas.

El uso de la distancia cuadrática media entre los valores reales y los valores predichos sigue siendo una de las posibles medidas de la calidad del modelo estimado, pero las pruebas fuera de muestra (*out-of-sample testing*) son el estándar. Finalmente, el uso de pruebas basadas en el estadístico t:

$$t - stat = \frac{Coef}{Std.Err}$$

Sigue siendo la base para la evaluación de la significancia del efecto de cada variable.

Sin embargo, esta flexibilidad tiene su precio: el protocolo para evaluar todas las especificaciones posibles es más complejo y menos transparente. La pregunta cómo seleccionar las variables explicativas sigue siendo relevante. Más importante aún, el analista debe considerar una cantidad extremadamente grande de especificaciones posibles (inormalmente infinitas!) para determinar, en una manera rigurosa, la que ofrece la mejor aproximación a los datos. En la práctica, los analistas se basan en la intuición o en un protocolo poco convincentes para seleccionar la especificación no lineal.




Figura 6: *Non-linear regression.*

2.2.3 Algoritmos de aprendizaje autónomo

La gran ventaja que ofrecen los algoritmos de aprendizaje autónomo es que proporcionan un protocolo transparente y automatizado para la búsqueda de la mejor especificación no lineal. En particular, todos estos algoritmos ofrecen respuestas sistematizadas a las siguientes preguntas:

1. ¿Cómo seleccionan los analistas las variables que entran en la regresión?
 - Hay un método automatizado para la selección de las variables explicativas (características).
2. ¿Cómo eligen los analistas la especificación de la relación (la función F)?
 - Dadas las variables explicativas, la búsqueda de la especificación que ofrezca la mejor aproximación también es automática.
3. ¿Cómo se evita el problema de sobreestimación?
 - La base de datos se divide aleatoriamente en dos submuestras: una muestra de entrenamiento utilizada para la estimación y una muestra de prueba utilizada para la evaluación de la calidad de la aproximación.

Todos los pasos están automatizados. La intervención del analista se limita a:

- La selección de la base de datos.
- La selección de la relación causal que se investiga: ¿qué es " y " y qué es " x "?
- La selección del algoritmo y su programación.

Terminamos con dos observaciones:

- Los algoritmos estandarizan y sistematizan la estimación de regresiones complejas. ¡Esto es una mejora!
- La pregunta sigue siendo si estos algoritmos representan inteligencia artificial generativa. ¿Es inteligencia artificial si el analista aún determina el método de trabajo (el algoritmo), el entorno de aprendizaje (datos) y los objetivos (relación entre y y x)?

2.2.4 Algoritmo "Random forest"

"Random forest" es uno de los algoritmos más populares en las analíticas de recursos humanos. A continuación, se presenta la intuición de los elementos principales de este algoritmo:

1. Determina en manera aleatoria la submuestra de *testing* y la submuestra de entrenamiento.

2. En cada iteración del algoritmo:

- 1) Dibujar en una manera aleatoria una submuestra de observaciones de la muestra de entrenamiento ("*bootstrapping*" una submuestra) y estimar un árbol de regresiones usando esta submuestra.
- 2) En cada nodo del árbol, elegir una muestra aleatoria de las variables explicativas y buscar la mejor especificación, dadas las variables seleccionadas.
- 3) Repetir este proceso muchas veces para "cultivar un bosque" de árboles de regresión, o sea, "*random forest*".

3. Usando la submuestra de prueba, para determinar la calidad de cada árbol, comparar las predicciones y los valores realizados.

Se dedica mucho esfuerzo a encontrar la forma más eficiente de buscar variables explicativas y la función óptima para cada grupo de variables explicativas.

2.2.5 GPT, ChatGPT, etc.

Los modelos de lenguaje de gran escala y **los algoritmos de aprendizaje por refuerzo** son la base de los productos recientemente desarrollados, conocidos como IA generativa. El problema que resuelven es dinámico: en el caso de GPT y ChatGPT, por ejemplo, cada interacción con un usuario constituye una etapa del problema. El objetivo de los algoritmos es ofrecer la mejor respuesta posible a los usuarios a largo plazo. En cada etapa, se aplican los métodos y algoritmos ya revisados.

La dinámica del problema introduce una complejidad adicional: para proporcionar la mejor respuesta posible a largo plazo, puede ser necesario experimentar al principio en lugar de ofrecer la mejor respuesta basada en datos previos. En términos matemáticos, este problema se conoce como el control óptimo de programas dinámicos con parámetros desconocidos. Es un problema clásico pero muy difícil. Existen diversos algoritmos utilizados para proporcionar soluciones a problemas aplicados. Los algoritmos de aprendizaje por refuerzo se han utilizado ampliamente en este contexto.

Lo que hace a GPT y ChatGPT exitosos es la introducción de **retroalimentación humana** en su algoritmo de aprendizaje por refuerzo. Es decir, los algoritmos utilizados en GPT y ChatGPT no son un sustituto de la inteligencia humana, sino un complemento de esta (ver Figura 7). Este es el elemento revolucionario de los productos relacionados: utilizan el potencial y las sinergias entre la inteligencia humana y los algoritmos de aprendizaje autónomos.




Figura 7: Representación visual de una iteración del algoritmo de aprendizaje por refuerzo con retroalimentación humana usado en el desarrollo de GPT. Fuente: OpenAI.

2.3 Gestión de la aplicación de IA a las analíticas de RRHH

La mayor parte del esfuerzo de los programadores se dedica a mejorar la eficiencia del algoritmo que busca la mejor especificación no lineal. Los analistas también dedican gran parte de su tiempo a problemas técnicos, como la selección del algoritmo, ajustes en los algoritmos, etc. Es decir, existe una tendencia de que los programadores y analistas pierdan de vista la perspectiva general: las consecuencias económicas del análisis y las implicaciones gerenciales.

Al mismo tiempo, la interpretación de los resultados y los métodos de evaluación de las especificaciones son los mismos en los métodos estadísticos automatizados que en las regresiones lineales y no lineales. Los gerentes deben centrarse en la interpretación, evaluación y deducción de decisiones. En ese sentido, un buen equipo de analistas de RRHH tiene sinergias y una clara división del trabajo:

- Los gerentes definen el problema.
- Los analistas redefinen el problema en términos estadísticos.
- Los programadores trabajan en los algoritmos.
- Los analistas revisan los resultados intermedios y ajustan el problema hasta encontrar una solución.
- Los analistas presentan los resultados finales.
- Los gerentes interpretan los resultados y toman decisiones.

Conclusión

Los departamentos de RRHH son unas de las unidades más orientadas al uso de IA y métodos estadísticos avanzados en las empresas modernas. Las principales áreas de aplicación incluyen: identificación de perfiles laborales, resumen de información de candidatos en conjuntos de datos, predicción del desempeño de candidatos y análisis del riesgo de rotación. Las etapas en el desarrollo de herramientas de RRHH son: limpieza y sistematización de datos, análisis exploratorio, desarrollo de una herramienta avanzada con alta capacidad de predicción, escalamiento del proyecto, incorporación de retroalimentación, institucionalización y transformación organizacional. El *trade-off* entre la precisión de las predicciones y la escala de generalización sigue siendo un desafío importante. Al mismo tiempo, muchos equipos de análisis no aplican de manera consistente medidas de desempeño para sus equipos analíticos, lo cual representa un problema significativo.

Las analíticas de RRHH también han avanzado en la aplicación de IA a sus operaciones. Los métodos estadísticos avanzados utilizados en el desarrollo de la IA son versiones automatizadas de métodos estadísticos clásicos. En consecuencia, todas las medidas de desempeño de los métodos estadísticos clásicos también se aplican a los métodos más avanzados y automatizados. Los gerentes deben centrarse en la definición del problema y la interpretación de los resultados, mientras que los analistas y programadores deben enfocarse en los detalles técnicos. Las buenas prácticas de gestión de datos son clave para el éxito de cada proyecto.

Preguntas:

- ¿Por qué cree que es difícil pasar del análisis de datos a herramientas analíticas para la toma de decisiones?
- ¿Por qué cree que la mayoría de los equipos de RRHH no tienen medidas de desempeño consistentes y persistentes de sus proyectos analíticas?
- ¿Cuál cree usted que es la diferencia entre las aplicaciones clásicas de los métodos estadísticos y los algoritmos de aprendizaje autónomo?
- ¿En qué tareas de RRHH cree que las herramientas de IA son complementarias a los humanos y en qué tareas son sustitutivas de los humanos?
- ¿Cuál es su propia experiencia con estas herramientas en su vida profesional?

Bibliografía

Broecke, Stijn (2017). *Future of Work*. OECD, available [here](#).

Davenport, Thomas H. (2019). *Is HR the Most Analytics-Driven Function?* Harvard Business Review, Published on April 18, 2019. Available [here](#). Related material are available [here](#).

Ferrar Onathan, Naomi Verghese, and Madhura Chakrabarti (2024). *Harnessing Data for Growth: The Impact of People Analytics*. Insights 222. Available [here](#)

Lesser, Eric, Peter DeBellis, and Marc Solow (2023). *High-Impact People Analytics Research*. Deloitte Special Report. Available [here](#)

Kropp, Brian and McRae, Emily Rose. (2022). "11 Trends that Will Shape Work in 2022 and Beyond" *Harvard Business Review*. 13 January 2022.

Sonnenberg, Mariëlle, Federico Bechini, Sietse Schröder, Caitlin van Mil (2024). *Our Real-Life Journey with GenAI in Skills and Talent Management*. Working paper. Available [here](#). Python code available [here](#).

Varian, Hal R. (2014). "Big Data: New Tricks for Econometrics." *Journal of Economic Perspectives*, 28 (2): 3-28.

Waters, Shonna, Erin Eatough, Shehzad Bashir, and Ian O'Keefe (2024). *People Analytics Across Company Growth Stages: Evolving Your Approach as You Scale*. White paper. Available [here](#).

Whitehouse, Mark, Mira Rojanasakul and Cedric Sam (2017). *Is Your Job About To Disappear?: QuickTake*. Bloomberg, published on June 22, 2017. Available [here](#).



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE