



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Clase N° 2

Usos y abusos de las herramientas analíticas

Uso de la inteligencia artificial en la gestión de recursos humanos

Docente

Raicho Bojilov

Contenido

Contenido	2
Introducción	4
1. Disponibilidad de datos	5
2. Calidad de datos.....	8
3. Datos, comportamiento estratégico y cambio estructural.....	10
4. Transparencia	11
5. Causalidad.....	12
5.1 Experimentos	14
5.2 Diferencia en diferencia.....	17
5.3 Regresiones de discontinuidad	18
5.4 Variables instrumentales	19
6. Discusión y conclusión	21
Bibliografía	22

Resultados de aprendizaje

- Discutir los requisitos relacionados con los datos para el éxito de proyectos analíticos de RRHH.
- Presentar los límites en el uso de herramientas analíticas de RRHH.
- Revisar métodos para evaluar el efecto de políticas en el contexto de RRHH.

Introducción

En esta clase, revisaremos las limitaciones y lecciones aprendidas en la aplicación de métodos estadísticos avanzados, específicamente la inteligencia artificial (IA), a la gestión de recursos humanos. Destacaremos la importancia del trabajo preliminar para el éxito final de cualquier proyecto analítico: la disponibilidad de los datos necesarios y la relevancia de la calidad de los datos. El desafío clave de cualquier proyecto analítico es que, por defecto, los datos históricos tienen una utilidad limitada para predecir el futuro; son útiles solo en condiciones muy específicas que exploraremos.

Además, los algoritmos de IA y los productos relacionados mejoran continuamente a través del uso de nuevos datos. En este contexto, las empresas tienen preocupaciones justificadas de que sus propios datos puedan ser utilizados por terceros, posiblemente en su contra. Al mismo tiempo, los creadores de herramientas analíticas son reacios a compartir detalles sobre sus algoritmos, ya que el funcionamiento de estos es su principal ventaja competitiva. Estos temas implican que los gerentes enfrentan decisiones difíciles.

Asimismo, tomar decisiones requiere elegir entre diferentes políticas y, por esta razón, los gerentes necesitan conocer el efecto de las diversas políticas disponibles. En otras palabras, esperan que los proyectos analíticos establezcan el efecto causal de las opciones de política que tienen. Sin embargo, sabemos que la correlación no implica causalidad; asegurar que un proyecto analítico establezca causalidad es complejo. En la parte final de la clase, exploraremos diversas estrategias empíricas para establecer causalidad.

1. Disponibilidad de datos

Los algoritmos de aprendizaje autónomo utilizan datos históricos. Por lo tanto, la relevancia de estos datos para la toma de decisiones en nuevos entornos y contextos, como nuevos productos, servicios, tecnología y maquinaria nueva, así como nuevas fábricas, es una preocupación clave. Los datos históricos son irrelevantes cuando la diferencia entre las operaciones previas y el nuevo contexto es drástica. Si el nuevo contexto es similar o muy similar a un contexto antiguo, problema o situación que ha sido analizada anteriormente, entonces los datos históricos relevantes pueden utilizarse como referencia. Además, cuando se consideran cambios marginales en un entorno estable, el pasado también puede usarse como referencia. Es responsabilidad de los gerentes determinar si, qué datos históricos y en qué contexto pueden o no utilizarse.

La disponibilidad limitada de datos es un problema típico. Con frecuencia, no se tienen exactamente las variables que se desean, por lo que se debe redefinir el problema en función de los datos disponibles. Nuevamente, los gerentes deben definir y redefinir el problema en colaboración con los analistas para determinar qué se puede y qué no se puede hacer. Además, las empresas generalmente solo tienen acceso a sus propios datos, mientras que los resultados dependen de la interacción entre la empresa y otros agentes del mercado. En otras palabras, casi siempre los proyectos analíticos se ven limitados por la ausencia de datos relevantes del mercado.

Otra limitación en el uso de herramientas analíticas está relacionada con el hecho de que algunas de las decisiones más impactantes, por definición, están asociadas con pocas o ninguna observación relevante, como la contratación de directores o el lanzamiento de nuevos productos. Existe un continuo entre los dos extremos: decisiones donde hay muchos datos relevantes y decisiones donde no hay datos relevantes. En este contexto, los analistas conocen la precisión de sus predicciones, mientras que la gerencia conoce las consecuencias del error. Por lo tanto, la colaboración entre los analistas y los gerentes es necesaria para determinar los costos y los beneficios esperados del uso de herramientas analíticas y el punto en el que el uso de nuevas herramientas analíticas deja de ser aceptable.

Si hay datos de mercado disponibles, entonces pueden utilizarse para realizar análisis en temas donde los datos de la empresa no sean suficientes. Normalmente, las empresas de consultoría cuentan con dichos datos y ofrecen productos relacionados. Sin embargo, todos los productos de estas empresas enfrentan un compromiso entre la generalidad de aplicación y la precisión de la predicción. Subcontratar el trabajo analítico a una empresa externa implica una pérdida de control: no se tiene información completa sobre los datos ni sobre el proceso. Sin estos elementos, es difícil determinar la precisión y los riesgos asociados con la implementación de las recomendaciones de la firma externa.

RETAIL OCTOBER 10, 2018 / 8:04 PM / UPDATED 5 YEARS AGO

Amazon scraps secret AI recruiting tool that showed bias against women

By Jeffrey Dastin

8 MIN READ



SAN FRANCISCO (Reuters) - Amazon.com Inc's [AMZN.O](#) machine-learning specialists uncovered a big problem: their new recruiting engine did not like women.

Common pitfalls and recommendations for using machine learning to detect and prognosticate for COVID-19 using chest radiographs and CT scans

[Michael Roberts](#) , [Derek Driggs](#), [Matthew Thorpe](#), [Julian Gilbey](#), [Michael Yeung](#), [Stephan Ursprung](#), [Angelica I. Aviles-Rivero](#), [Christian Etmann](#), [Cathal McCague](#), [Lucian Beer](#), [Jonathan R. Weir-McCall](#), [Zhongzhao Teng](#), [Effrossyni Gkrania-Klotsas](#), [AIX-COVNET](#), [James H. F. Rudd](#), [Evis Sala](#) & [Carola-Bibiane Schönlieb](#)

[Nature Machine Intelligence](#) **3**, 199–217 (2021) | [Cite this article](#)

90k Accesses | **446** Citations | **1196** Altmetric | [Metrics](#)




Figura 1. Artículos relacionados con los temas tratados en el texto

2. Calidad de datos

La calidad de los datos es un factor decisivo para el éxito de un proyecto analítico. Muy a menudo, los analistas trabajan en un proyecto durante meses, solo para descubrir problemas significativos con los datos que hacen que el proyecto sea imposible de finalizar o que requiera una redefinición considerable del problema y trabajo adicional. El error aquí es empezar a trabajar antes de estudiar bien los datos.

El primer paso es documentar el proceso de recopilación de los datos: quién los recopiló, cuándo y cómo. Cuando el conjunto de datos toma la forma de variables, es importante contar con una descripción de cada variable: qué representa, cuáles son sus unidades, si han ocurrido cambios en su definición, etc.

El siguiente paso es determinar la relevancia de los datos. Algunos de los problemas relacionados se discutirán más adelante en este texto. Aquí nos enfocamos en el efecto de la calidad de los datos en su relevancia:

- ¿Existen errores en el registro de los datos? ¿Son estos errores aleatorios o sistemáticos?
- ¿Las variables están midiendo lo que realmente necesitamos medir? En el contexto de recursos humanos, un ejemplo típico es la distancia al trabajo. Las preguntas clave son cómo se mide:
 - ¿Se mide en términos de tiempo o kilómetros?
 - ¿Se trata de un entorno urbano, suburbano o rural?
 - Cuando lo medimos en un contexto urbano, ¿consideramos la existencia de rutas alternativas, los atascos de tráfico, la imprevisibilidad del viaje, etc.?

- ¿Es el conjunto de datos representativo o no? Si los datos solo provienen de una parte de la población, puede existir un sesgo de selección. Algunos ejemplos:
 - La selección de candidatos durante el proceso de contratación afecta la evaluación de una herramienta de contratación para predecir la productividad.
 - La autoselección durante el proceso de contratación: los candidatos también deciden si aceptan o no una oferta.

Ejemplo:

Roberts et al. (2021) revisan el uso de radiografías de tórax en el diagnóstico de Covid-19 utilizando algoritmos de aprendizaje autónomo. Una de las conclusiones del estudio es que la calidad de los datos utilizados en la mayoría de los trabajos empíricos sobre este tema está comprometida, lo que afecta los resultados. Un problema particularmente interesante está relacionado con el análisis visual de radiografías de tórax por algoritmos de aprendizaje autónomo. Es posible tomar la radiografía mientras los pacientes están de pie o acostados. Los pacientes en mejor estado de salud generalmente se realizan la radiografía estando de pie. La cuestión clave es que existen pequeñas diferencias técnicas en las radiografías según el método utilizado. Sin un control adecuado sobre la fuente de los datos, los algoritmos de aprendizaje autónomo pueden atribuir un significado médico erróneo a estas diferencias. El resultado es un análisis espurio sin valor médico.

3. Datos, comportamiento estratégico y cambio estructural

Si la empresa tiene una participación significativa en los mercados relevantes, la implementación de políticas drásticamente nuevas hace que los datos históricos sean irrelevantes para su uso futuro. Un ejemplo extremo ilustra este punto: si una empresa es el único empleador en una ciudad, ella misma es el mercado. Cuando cambia drásticamente sus criterios y políticas de contratación, transforma el mercado de manera significativa, creando un nuevo entorno en el cual los datos históricos dejan de ser útiles para el análisis después del cambio.

Otro problema está relacionado con el comportamiento estratégico humano. Cuando se produce un cambio en la política de una empresa, otros participantes del mercado reaccionan estratégicamente. Un ejemplo clásico del uso de la inteligencia artificial está relacionado con los fondos de cobertura. Estos fondos han estado utilizando algoritmos de aprendizaje autónomo para analizar los informes de empresas. Al darse cuenta de esto, las empresas afectadas han ajustado sus informes para influir en el análisis que realizan los fondos de cobertura.

En el contexto de recursos humanos, si una empresa cambia sus criterios y anuncia una nueva política, los candidatos adaptan su comportamiento: ajustan sus CV, incluyen o eliminan palabras clave, cambian su forma de presentarse en las entrevistas, etc. Como resultado, el entorno cambia y el significado de las respuestas también, lo que nuevamente puede hacer que los datos históricos sean irrelevantes.

En resumen, los gerentes siempre deben considerar cómo sus decisiones afectan la relevancia de los datos históricos para el trabajo futuro. Esto es más fácil decirlo que hacerlo, ya que la realidad es más compleja y el contexto de cada empresa es único. Aun así, las preguntas clave que los gerentes deben plantearse son:

¿Qué significa tener una "participación significativa" en el mercado relevante?

¿Qué tan significativo es el cambio en la política de la empresa?

4. Transparencia

La sección anterior proporciona fuertes incentivos para no revelar los resultados de los proyectos analíticos al público. También existen otras consideraciones intuitivas para no hacerlo: un anuncio público de los resultados y los cambios en las políticas relacionados compartiría los conocimientos de la empresa con el resto de la industria sin ningún costo. Muy a menudo, los propios gerentes no tienen idea de por qué el algoritmo hace alguna recomendación; por lo tanto, no saben cómo ni cuándo intervenir.

Incluso si están completamente informados sobre las herramientas analíticas, la falta de transparencia asociada también puede tener efectos negativos:

- Una comunicación deficiente con los candidatos y empleados puede generar la impresión de arbitrariedad y falta de confianza, lo que podría tener efectos negativos a largo plazo.
- Ya sea de manera intencionada o no, los algoritmos pueden utilizar ciertas variables como indicadores indirectos para implementar discriminación en algunas dimensiones:
 - **Género:** información del nombre, respuestas a pruebas psicométricas, etc.
 - **Clase social y educación:** ubicación geográfica (distancia al trabajo, dirección del hogar) y análisis del vocabulario y las conversaciones.

Por lo tanto, es necesario insistir en un resumen no técnico de los principales criterios y razones de las decisiones, que debe ser comunicado tanto a los gerentes como a los candidatos/empleados, al igual que se hacía en el mundo previo a la IA.

5. Causalidad

Cuando los gerentes toman decisiones, eligen entre alternativas de políticas. Las herramientas analíticas pueden ayudar estimando las consecuencias de cada alternativa. Desafortunadamente, las aplicaciones de los algoritmos de aprendizaje automático no se centran en la causalidad, es decir, en estimar el efecto de las alternativas de política en los resultados de la empresa. Los gerentes quisieran saber lo siguiente para cada alternativa de política:

- "La política X causa un efecto Y".
- "Cuando cambiamos los gastos en la política X en un 1%, el resultado es un aumento en Y de $\beta\%$ ".

Los algoritmos de aprendizaje autónomo utilizan datos para predecir una variable en función de otras variables. Se centran en obtener la mejor aproximación a los datos para un modelo del tipo: "¿Cuál es la mejor aproximación de la relación entre la variable Y y la variable X?" La inferencia causal en la mayoría de los casos aplicados no es una preocupación prioritaria.

En este contexto, los analistas pueden aprender mucho de los econométristas. La econometría, que aplica métodos estadísticos a cuestiones económicas, utiliza estos métodos para la predicción, la inferencia y la modelización causal de relaciones económicas. En este caso, la inferencia es el objetivo principal.

Ejemplo:

La contratación es fundamental para el éxito de una empresa. Es importante determinar cuáles son las principales características de los candidatos que predicen su desempeño y retención en el futuro. Algunas consideraciones típicas incluyen educación, experiencia y habilidades innatas. Sin embargo, el hecho de que las habilidades estén positivamente correlacionadas con los resultados educativos y la experiencia laboral plantea un problema.

Es probable que la alta habilidad sea una de las razones por las cuales una persona logra excelentes resultados educativos o tiene un historial laboral impresionante. De hecho, puede darse el caso de que la educación y la experiencia laboral sean simplemente señales de alta habilidad y nada más. Es decir, una vez que se controla su efecto como indicadores de habilidad, la educación y la experiencia pueden no tener poder predictivo independiente

sobre las perspectivas de un candidato. Por lo tanto, surge la pregunta de si la educación y la experiencia pueden predecir el desempeño y la retención futura de los empleados, y en qué medida.

La respuesta a esta pregunta es relevante para las políticas de contratación de la empresa. Por ejemplo, si la educación y la experiencia son indicadores perfectos de las habilidades y del desempeño futuro, la empresa no necesita desarrollar ni utilizar pruebas/encuestas durante el proceso de contratación. Por el contrario, si la educación y la experiencia no están relacionadas con las habilidades innatas y las predice el éxito futuro, la empresa deberá invertir en el desarrollo de una encuesta o prueba de contratación para seleccionar a los candidatos adecuados. Generalmente, la realidad se encuentra en un punto intermedio entre estos extremos. En este caso, para tomar una buena decisión, es importante cuantificar el impacto de la educación, la experiencia y la herramienta de contratación utilizada por la empresa.

En el contexto de la inferencia causal a partir de datos observacionales, nuestras principales preocupaciones son la eliminación del sesgo de selección y el sesgo por variables omitidas. Se puede pensar en estos como dos tipos diferentes de variables de confusión. La diferencia es que el sesgo de selección influye en quién termina en el grupo de tratamiento, mientras que el sesgo por variables omitidas se debe a factores externos relacionados tanto con el tratamiento como con el término de error. No incluir estas variables en el modelo puede sesgar la estimación del efecto del tratamiento.

El sesgo de selección y el sesgo por variables omitidas explican por qué los promedios pueden ser engañosos. Para demostrarlo con un ejercicio de pensamiento rápido, consideremos una empresa donde los trabajadores con mayor antigüedad tienen un mejor desempeño. ¿Podemos concluir que el desempeño mejora con la antigüedad porque los empleados acumulan experiencia relevante con el tiempo? No necesariamente...

Es posible que los empleados efectivamente aprendan a trabajar de manera más eficiente con el tiempo. Sin embargo, también puede suceder que los empleados con bajo desempeño abandonen la empresa o sean despedidos en los primeros meses. Como resultado, el desempeño **promedio** de los

empleados restantes aumenta cada mes, pero solo debido a la selección y no a una mejora real en el desempeño con la antigüedad.

Las secciones 6.1 a 6.4 revisan las estrategias empíricas más utilizadas para establecer la causalidad:

- **Sección 6.1:** presenta la solución más intuitiva y sólida al problema de la causalidad: los experimentos, o en términos profesionales, las aplicaciones piloto.
- **Sección 6.2:** analiza cómo evaluar el impacto de una política implementada utilizando datos históricos y un modelo de regresión de diferencias en diferencias.
- **Sección 6.3:** considera el mismo problema que la Sección 6.2, pero presenta una solución alternativa basada en el modelo de regresión de discontinuidad.
- **Sección 6.4:** expone brevemente el uso de variables instrumentales para establecer causalidad.

5.1 Experimentos

Los experimentos aleatorios funcionan asegurando que el estado de tratamiento no esté relacionado con otros factores (observados y no observados): si tomamos una muestra de población lo suficientemente grande y asignamos aleatoriamente los sujetos a los grupos de tratamiento y control, esto debería ser suficiente para permitir una interpretación causal. En el mundo real, las empresas suelen lanzar proyectos piloto: si estos proyectos piloto implican una selección aleatoria en el tratamiento, entonces, en la práctica, el proyecto piloto es un experimento.

Existen tres tipos de experimentos: **experimentos de laboratorio**, **experimentos de campo** y **experimentos naturales**. Cada tipo tiene sus ventajas y limitaciones. A continuación, revisamos en detalle cada tipo:

- **Experimentos de laboratorio:** incluyen un grupo de tratamiento y un grupo de control sin tratamiento. La asignación es aleatoria. El tratamiento se define en un entorno controlado y estilizado. Ejemplos incluyen grupos de enfoque en marketing, etc. El principal desafío de los

experimentos de laboratorio es diseñar un entorno que refleje las características clave del fenómeno que se quiere estudiar.

- **Experimentos de campo:** asignan a los participantes de manera aleatoria a un grupo de tratamiento y un grupo de control en un entorno realista. La inferencia es más confiable, pero los efectos de confusión son más probables, ya que el entorno no está completamente controlado. Por esta razón, los efectos que se miden a veces reflejan no solo lo que los analistas desean medir. Este es el principal desafío de los experimentos de campo.
- **Experimentos naturales:** son similares a los experimentos de campo, pero la diferencia entre los dos tipos está relacionada con sus orígenes. Un experimento de campo es premeditado y planificado, mientras que un experimento natural ocurre debido a accidentes, errores en la implementación, shocks externos, etc.

El beneficio más importante de los experimentos es que, cuando están bien diseñados e implementados, solo requieren comparar los promedios de los individuos tratados (grupo de tratamiento) con los individuos no tratados (grupo de control). A continuación, consideramos un ejemplo para ilustrar este punto.

La **Figura 1** analiza el efecto de un programa de capacitación ofrecido por una empresa. La empresa asigna aleatoriamente a sus nuevos empleados a dos programas de capacitación alternativos. Los empleados asignados al **Programa A** participan en un programa piloto de formación y constituyen el **grupo de tratamiento**. Los empleados asignados al **Programa B** siguen el programa de formación existente en la empresa y constituyen el **grupo de control**. El eje horizontal representa el tiempo y muestra el momento de implementación del programa piloto. El eje vertical representa la productividad promedio. El grupo de tratamiento está representado por **G=1** y el grupo de control por **G=0**.

A su vez, muestra visualmente que la diferencia entre el desempeño promedio de los dos grupos después de la implementación del programa es suficiente para evaluar el efecto global del programa piloto en la productividad.

La **complejidad de los experimentos** no está relacionada con los métodos estadísticos requeridos para su evaluación, sino en su diseño. Por ejemplo, en el contexto de la evaluación del programa piloto de capacitación, es necesario verificar que la asignación sea aleatoria y que la aceptación y finalización del programa no sufra de sesgo de selección. El experimento presenta **sesgo de selección** si, por ejemplo, los empleados mayores tienen más probabilidades de rechazar un programa piloto de formación que requiere un uso intensivo de herramientas digitales. En este caso, no podemos estar seguros de lo que realmente mide el experimento: ¿el efecto del programa piloto de formación o las mejores habilidades digitales de los empleados más jóvenes?

Además, debemos asegurarnos de que los participantes de los dos grupos no compartan el mismo espacio de trabajo. La razón es que, cuando comparten el mismo espacio, las amistades pueden dar lugar a la transferencia de conocimientos y experiencia, lo que podría llevar a subestimar la diferencia en el impacto de los dos programas.

Para resumir, los experimentos son el estándar de oro en la evaluación de políticas. Los resultados de un experimento bien diseñado son fáciles de interpretar y no requieren métodos estadísticos avanzados. El principal desafío está relacionado con el diseño experimental.




Figura 2. Estimación del efecto de tratamiento usando experimentos

5.2 Diferencia en diferencia

Causalidad: diferencia en diferencia

Cambios de política en el momento T, hay dos grupos después de T, el tratado por la política (grupo de tratamiento) y el grupo no tratado (grupo de control).

Modelo econométrico es:

$$y = X\beta + \alpha_1 I_T + \alpha_2 I_T I_G + \epsilon$$

Donde I_T es un indicador igual a 1 después de T y 0 antes de T. I_G es un indicador igual a 1 si una persona está en el grupo de tratamiento y 0 si la persona está en el grupo de control. El coeficiente de interés es α_2 .




Figura 3. Estimación del efecto de tratamiento usando regresiones de diferencias en diferencias

En comparación con los experimentos, en este contexto la selección en los grupos de tratamiento y control puede no ser aleatoria, pero las diferencias entre los dos grupos deben ser aditivas. La Figura 2 muestra la aplicación del método en el contexto del programa piloto de formación. Cuando las diferencias en productividad entre los dos grupos son aditivas, pueden eliminarse tomando diferencias: antes y después para cada grupo (para eliminar los elementos invariantes en el tiempo que determinan el rendimiento de cada grupo) y entre los dos grupos. Formalmente, el efecto del tratamiento es igual a:

$$\begin{aligned} & (Productividad_1^{antes} - Productividad_1^{después}) \\ & - (Productividad_0^{antes} - Productividad_0^{después}) \end{aligned}$$

5.3 Regresiones de discontinuidad

La "regresión de discontinuidad" es un método que aprovecha puntos de corte arbitrarios o eventos que simulan una asignación aleatoria. Por ejemplo, en el

contexto de nuestro programa de capacitación, los empleados recién contratados pueden estar obligados a participar en el programa piloto solo si obtienen una puntuación de 50 o menos en una prueba de nivel inicial. Los empleados justo por debajo y justo por encima de 50 son similares, y algunos reciben el tratamiento mientras que otros no; es decir, podemos estimar el efecto (local) de la capacitación para estos empleados (por ejemplo, entre 49 y 51) simplemente comparando la productividad promedio de los grupos tratados (entre 49 y 50) y de control (entre 50 y 51).




Figura 4. Estimación del efecto de tratamiento usando regresiones de discontinuidad

5.4 Variables instrumentales

La idea clave es aprovechar una variable externa (un instrumento) que simule una asignación aleatoria. Por ejemplo, supongamos que desea estudiar el impacto causal de un programa de capacitación presencial en el desempeño laboral. La proximidad al centro de capacitación podría utilizarse como un instrumento que influye en la participación en la capacitación, ya que los empleados que viven más cerca del centro podrían tener más probabilidades

de asistir al programa, pero esta proximidad no afectaría directamente el desempeño laboral. Así, la cercanía al centro puede emplearse como un proxy para determinar quiénes están en el grupo de tratamiento y quiénes en el grupo de control.

Es posible contar con más de una variable instrumental. El capítulo 4 de Cameron y Trivedi (2010) ofrece una presentación más avanzada y técnica sobre este material.

6. Discusión y conclusión

La gestión de recursos humanos no involucra únicamente al departamento de RRHH; cada unidad define sus propias tareas para su grupo analítico, lo que a menudo resulta en la falta de un enfoque integrado. Este problema es especialmente grave al evaluar el efecto de los incentivos, ya que estos influyen en la productividad de la empresa no solo a través del esfuerzo y la motivación, sino también mediante su impacto en la postulación, selección, autoselección y rotación de empleados.

Los analistas no son expertos en negocios y los expertos en negocios no son especialistas en inteligencia artificial. Por esta razón, su cooperación y comunicación son obligatorias para el éxito de cualquier proyecto analítico. Los gerentes deben saber cómo plantear el problema y cómo interpretar los resultados considerando el efecto general, sin ignorar los efectos colaterales. Los analistas deben comprender la misión definida por los gerentes para que, al realizar ajustes técnicos, sigan dicha misión.

Concluimos la clase con un **ejercicio práctico** relacionado con su propio contexto profesional. Por favor, definan un tema que deseen investigar utilizando datos de sus propias instituciones y respondan las siguientes preguntas: ¿Cuál es el problema que desean estudiar?

- ¿Cuál es el problema que desean estudiar?
- ¿Cuál es la hipótesis principal que les gustaría investigar?
- ¿Por qué es importante para su institución?
- ¿Cuál es la muestra?
 - Periodo, variables, lugares
- ¿La muestra es relevante y adecuada?
 - Cambios en los mercados, organización de empresas, incentivos, programas, etc.
- ¿Pueden utilizar un experimento? Si no, ¿cómo planean establecer la causalidad.

Bibliografía

Akerlof, G. A. (1970). The market for "lemons": Quality uncertainty and the market mechanism. *The Quarterly Journal of Economics*, 488-500.

Cameron, C., Trivedi, P. (2006). *Microeconometrics*. Cambridge University Press.

Choi, C. (2023). Predicting Black Swan Disasters with Ai. *IEEE Spectrum*, publicado el 3 de enero 2023. Disponible en: <https://spectrum.ieee.org/weather-predicting-black-swan>

Dustin, J. (2018). Insight - Amazon scraps secret AI recruiting tool that showed bias against women. *Reuters*, Publicado el 10 de octubre 2018. Disponible en: <https://www.reuters.com/article/world/insight-amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK0AG/>

Spence, M. (1973). "Job Market Signaling". *Quarterly Journal of Economics*. **87** (3): 355-374.

Roatch, J. (2024). From Correlation to Causation: Leveling Up People Analytics with Econometrics. Source: <https://jacksonroatch.substack.com/p/from-correlation-to-causation-leveling>

Sonnenberg, Mariëlle, Federico Bechini, Sietse Schröder, Caitlin van Mil (2024). Our Real-Life Journey with GenAI in Skills and Talent Management. Working paper. Disponible en: <https://www.linkedin.com/pulse/our-real-life-journey-genai-skills-talent-management-code-van-mil-caise/>

Spence, M. (2002). "Signaling in Retrospect and the Informational Structure of Markets". *American Economic Review*. **92**

Varian, Hal R. (2014). "Big Data: New Tricks for Econometrics." *Journal of Economic Perspectives*, 28 (2): 3-28.



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE